GALAXIEN SAILKAPENA KONBOLUZIO-SAREAK ERABILIZ

Josu Aguinaga
Ikaslea
Euskal Herriko Unibertsitatea (EHU)
Donostia
jaguinaga004@ikasle.ehu.eus

LABURPENA

Gizakientzat galaxiak eskuz sailkatzea ataza luzea da. Txosten honetan, Galaxy Zoo datu-multzoko galaxien $12\,750$ irudi erabiltzen dira Residual Neural Network (ResNet) arkitekturan oinarritutako Convolutional Neural Network (CNN) bat entrenatzeko. Entrenatutako ereduak $\%$ 93,67ko doitasuna-maila lortu du eta galaxien morfologia iragartzeko erabili daiteke. Jarraian, lan honetan erabilitako datu-multzoa aurkitu daiteke:

`https://www.kaggle.com/competitions/galaxy-zoo-the-galaxy-challenge/data`

***K*eywords** ResNet · Galaxiak: morfologia

1 Arazoaren deskribapena

Galaxy Zoo proiektuan boluntarioek galaxien irudiak sailkatu behar dituzte galdera-sorta bati erantzunez. Borondatezko lan honek arazo bat du: milaka galaxien sailkapenerako datuak eskuratzeko jende gehiegi erabiltzen da, eta kudeaketa okerrak arazoak ekar ditzake.

Lan honen helburua edozein galaxiaren morfologia zuzen iragartzen duen sistema bat sortzea da.

2 Datuen deskribapena

Kaggle-tik eskuratutako datu-multzoak fitxategi hauek ditu:

- `images_training`: galaxien $61\,578$ irudi JPG formatuan. Fitxategi bakoitzaren izena fitxategi bakoitzari dagokion galaxiaren *GalaxyId* da.
- `solutions_training`: Entrenamenduko irudi bakoitzaren sailkapenen probabilitate banaketa.
- `images_test`: galaxien $79\,975$ irudi JPG formatuan. Fitxategi bakoitzaren izena fitxategi bakoitzari dagokion galaxiaren *GalaxyId* da.
- `all_ones_benchmark`: Balio guztiak bat zenbakiarekin dituen eredu fitxategia.
- `all_zeros_benchmark`: Balio guztiak zero zenbakiarekin dituen eredu fitxategia.
- `central_pixel_benchmark`: Entrenamenduko irudi bakoitzaren sailkapenen probabilitate banaketa, irudiaren erdiko kolorearen arabera multzokatuta.

Eredua entrenatzeko galaxien irudiak eta aurresandako etiketak behar dira. Hori dela eta, `images_training` eta `solutions_training` karpetetako fitxategiak bakarrik erabili dira. Horrez gain, haietatik bakarrik $15\,000$ irudi erabili dira. Helburua ez da doitasun handiena lortzea, baizik eta eredua entrenatzeko denbora murriztea eta eredu on bat eraikitzea.

Hautatutako galaxia guztiek 424×424 tamaina dute eta kolorean daude.

2.1 Galaxien morfologia

Irudiak sailkatzeko pertsonek erabaki-zuhaitz bati erantzuten diote. Erantzun hauek bildu egiten dira, eta erantzun bakoitzaren agerpen probabilitatea kalkulatu egiten da eta ezaugarri gisa adierazten da.

Q1: Objektua galaxia leun bat, ezaugarridun/diskodun galaxia bat edo izar bat da?

- Leuna — Class1.1 (joan **Q7**era)
- Ezaugarriduna edo diskoduna — Class1.2 (joan **Q2**ra)
- Izarra edo artefaktua — Class1.3 (joan **bukaera**ra)

Q2: Galaxiaren ertza ikusten da?

- Bai — Class2.1 (joan **Q9**ra)
- Ez — Class2.2 (joan **Q3**ra)

Q3: Barrarik ba al dago?

- Bai — Class3.1 (joan **Q4**ra)
- Ez — Class3.2 (joan **Q4**ra)

Q4: Eredu espiralik ba al dago?

- Bai — Class4.1 (joan **Q10**era)
- Ez — Class4.2 (joan **Q5**era)

Q5: Nolako nabarmena da erdiko tontorra?

- Tontorrik ez — Class5.1 (joan **Q6**ra)
- Antzeman daiteke — Class5.2 (joan **Q6**ra)
- Begi bistakoa — Class5.3 (joan **Q6**ra)
- Nagusia — Class5.4 (joan **Q6**ra)

Q6: Galaxiak ezaugarri “arrarorik” ba al du?

- Bai — Class6.1 (joan **Q8**ra)
- Ez — Class6.2 (joan **bukaera**ra)

Q7: Nolako biribila da galaxia leuna?

- Guztiz biribila — Class7.1 (joan **Q6**ra)
- Tartekoa — Class7.2 (joan **Q6**ra)
- Zigarro-itxurakoa — Class7.3 (joan **Q6**ra)

Q8: Zein da ezaugarri arraroa?

- Eraztuna — Class8.1 (joan **bukaera**ra)
- Lentea edo arkua — Class8.2 (joan **bukaera**ra)
- Nahasia — Class8.3 (joan **bukaera**ra)
- Irregularra — Class8.4 (joan **bukaera**ra)
- Bestelakoa — Class8.5 (joan **bukaera**ra)
- Bat-egitea — Class8.6 (joan **bukaera**ra)
- Hauts-bidea — Class8.7 (joan **bukaera**ra)

Q9: Zein itxura du tontorrak ertza ikusi daitekeen galaxian?

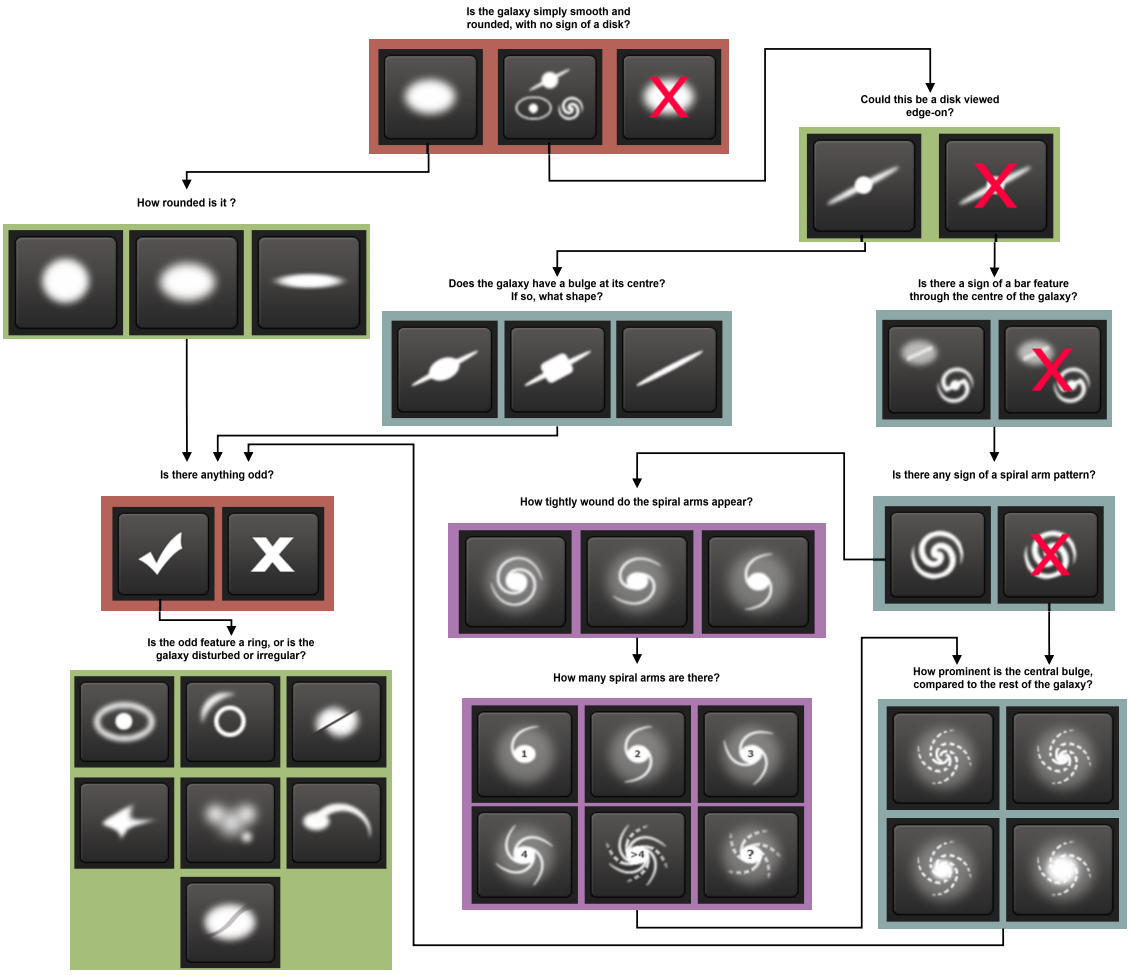
- Biribila — Class9.1 (joan **Q6**ra)
- Kutxa-itxurakoa — Class9.2 (joan **Q6**ra)
- Tontorrik ez — Class9.3 (joan **Q6**ra)

Q10: Nolako gertu daude beso espiralak?

- Gertu — Class10.1 (joan **Q11**era)
- Tartekoa — Class10.2 (joan **Q11**era)
- Solte — Class10.3 (joan **Q11**era)

Q11: Zenbat beso espiral daude?

- 1 — Class11.1 (joan **Q5**era)



Irudia 1: Galaxia baten morfologia erabakitzen duen erabaki-zuhaitza.

- 2 — Class11.2 (joan **Q5**era)
- 3 — Class11.3 (joan **Q5**era)
- 4 — Class11.4 (joan **Q5**era)
- Lau baino gehiago — Class11.5 (joan **Q5**era)
- Ez dakit — Class11.6 (joan **Q5**era)

Erabaki-zuhaitza diagrama batekin laburtu daiteke, ikusi 1 Irudia.

2.2 Emaitzak

Emaitzen CSV fitxategiko zutabeek etiketak adierazten dituzte eta errenkadek galaxiak. Taulako lehenengo zutabeak galaxia guztien identifikatzaileak gordetzen ditu; gainontzeko 37 zutabeek galaxiak etiketa hori izateko probabilitatea gordetzen dute.

Galdera baten ezaugarri-multzoaren probabilitatearen batura 1 da. Jarraipen-galdera gisa sortutako ezaugarri-multzoaren batura ere 1 da, aurreko erantzunaren ezaugarriaren probabilitatearekin murriztu aurretik.

3 Diseinua eta inplementazioa

Datuen laginketarako *sklearn* erabili da eta CNNaren inplementaziorako *torch* liburutegia erabili da.

3.1 Laginketa

Hasierako 61 578 irudietatik ausaz 15 000 irudiko azpi-multzo bat hautatu da. Ondoren, entrenamendurako, balidaziorako eta probetarako datu-multzo hau hiru azpi-multzotan banatuko da, % 75eko, % 15eko eta % 15eko banaketarekin hurrenez hurren.

3.2 Aurretratamendua

Hiru datu azpi-multzoei hiru oinarrizko transformazio egingo zaizkie:

Erdiko mozketa Irudia, irudiaren erditik neurtuta, 256×256 tamainara moztuko da. Galaxien informazio garrantzitsuena irudien erditik gertu dago. Transformazio hau aplikatuta informazio oso gutxi galduko dugu eta irudi bakoitzaren aztarna txikituko dugu.

Tamaina aldatzea Irudiaren bereizmena 128×128 tamainara txikituko dugu. Gure baliabideak mugatuak dira eta transformazio honek CNNak ikasi beharko duen informazio kopurua txikitzen du.

Normalizazioa Pixelen balioak eraldatzen ditu $[0, 1]$ tartean mugatzeko eta $batezbestekoa \approx 0$ izan dezaten, entrenamendua hobetzeko helburuarekin.

Entrenamenduko laginei *data augmentation* transformazioak aplikatuko zaizkie gainegokitzapena saihesteko.

Ausazko biraketa Irudia ausaz biratzen da eta irudia karratu mantentzea zarata (pixel beltzak) gehitzen zaie ertzei.

Ausazko iraultze horizontala : Irudia ausaz iraultzen da horizontalki.

Ausazko iraultze bertikala Irudia ausaz iraultzen da bertikalki.

Kolore jitterra Argitasuna eta kontrastea ausaz eguneratzen dira $\pm\%$ 10eraino irudi aldakuntzak simulatzeko.

3.3 Neurona-sarea

ResNeten oinarritutako CNN bat inplementatu da [1]. Zehazki, *bottleneck* hondar-blokeak erabili dira 50 geruzako ResNet arkitektura eraikitzeko.

3.3.1 Hondar-blokea

Hondar-blokeak hiru konboluzio bloke sekuentzia batean ditu. Bloke bakoitzak konboluzioa egiten du, irteerak normalizatzen ditu eta *ReLU* aktibazio funtzio batetik pasatzen ditu ez-linealtasuna gehitzeko. Azkeneko blokean, ordea, aktibazio funtzioa beranduago aplikatzen da.

1. Kanalen dimentsioa murrizten du eta dimentsio espazialak ere murrizten ditu `stride` pasatzen bazaio. Parametroak: `in_channels` sarrera kanalak, `1x1` tamainako `out_channels` geruzak, pausoa `stride` eta betegarria `0`.
2. `3x3` tamainako konboluzioa aplikatzen du dimentsio espazialak aldatu gabe. Parametroak: `out_channels` sarrera kanalak, `3x3` tamainako `out_channels` geruzak, pausoa `1` eta betegarria `1`.
3. Kanalen dimentsioa berriz atzera handitzen du. Parametroak: `out_channels` sarrera kanalak, `1x1` tamainako `4 × out_channels` geruzak, pausoa `1` eta betegarria `0`.

Konboluzio eragiketa bakoitzaren ondoren normalizazioa exekutatzen da. Erabiltzen den `BatchNorm2d` moduluak jada baditu ikasten diren γ eta β parametro propioak. Beraz, konboluzio geruzek ez dute alborapen propio bat izango.

$$y = \frac{x - \mathrm{E}\left[x\right]}{\sqrt{\mathrm{Var}\left[x\right] + \epsilon}} * \gamma + \beta$$

Sekuentziako azkeneko konboluzio blokea exekutatu ondoren, hondar-blokea gehitu egiten da aurreko blokearen irteerara. Hondar-bloke hau laburbide identitatea da sarrera eta irteera dimentsioak edo dimentsio espazialak ez badira aldatzen; aldatzen badira, identitatea lehenengo laburbide funtzio batetik igarotzen da azkeneko blokera gehitu aurretik.

3.3.2 Eredua

Sortu den CNN ereduaren diseinua jarraian azaltzen da:

1. `3` sarrera kanal `64` kanaletara transformatzen dituen konboluzioa, `7x7`ko iragazkia erabiliz `2`ko pausoa eta `3`ko betegarria duena (dimentsio espazialak erdira murrizteko). Ondoren, honakoak aplikatzen dira: normalizazioa, ReLU aktibazio funtzioa eta `3x3`ko max pooling azpilaginketa-geruza `2`ko pausoa eta `1`eko betegarria duena (dimentsio espazialak erdira murrizteko).
2. `64` irteera kanal dituzten `3` Bottleneck-bloke sorta, lehenengo blokeko lehenengo konboluzio-geruzan `1`eko pausoa duena.
3. `128` irteera kanal dituzten `4` Bottleneck-bloke sorta, lehenengo blokeko lehenengo konboluzio-geruzan `2`ko pausoa duena.
4. `256` irteera kanal dituzten `6` Bottleneck-bloke sorta, lehenengo blokeko lehenengo konboluzio-geruzan `2`ko pausoa duena.
5. `512` irteera kanal dituzten `3` Bottleneck-bloke sorta, lehenengo blokeko lehenengo konboluzio-geruzan `2`ko pausoa duena.
6. Sailkapen geruzak:
   - Azkeneko bottleneck-blokeak emandako `2048` kanalei average pooling-a aplikatzen zaio `1x1` tamainako geruzak lortzeko.
   - Galdera bakoitzarentzako guztiz konektatutako geruza bat, `2048` sarrera kanal galdera bakoitzak izan ditzakeen erantzun kopurura murrizten duena.

Konboluzio-geruzen eta guztiz konektatutako geruzen pisuak hasieratzeko Kaiming edo He hasieraketa erabiliko da. Normalizazio-geruzen pisuak `1`ean eta normalizazio-geruzen eta guztiz konektatutako geruzen alborapenak `0`an hasieratzen dira.

Kanalak edo dimentsio espazialak aldatzen badira sortako lehenengo blokeak laburbide funtzio berezi bat beharko du. Hala bada, laburbide funtzioa `in_channels` sarrera kanal `4 * out_channels` irteera kanaletara bihurtzen dituen konboluzio gisa definitzen da, `1x1` tamainako iragazkia eta `first_block_layer_stride` pausoa erabiliz, eta normalizazioa aplikatzen zaio gero.

Sailkapen geruza partekatuaren irteera (ezaugarriak) `11` guztiz konektatutako geruza guztietara pasatzen da. Lehenengo guztiz konektatutako geruzaren irteera `softmax` aktibazio funtziora igarotzen da probabilitate guztien batura `1` izateko, eta gainontzeko geruzen irteerak normalizatu egiten dira `sigmoid` aktibazio funtzioetara pasatuz eta dagozkien **Q1**eko iragarpenaren probabilitateekin murriztuz.

- **Q7**: `q1_smooth`-k murriztua (Class1.1).
- **Q2**, **Q3**, **Q4**, **Q5**, **Q9**, **Q10**, **Q11**: `q1_features`-k murriztua (Class1.2).
- **Q6**, **Q8**: `1 - q1_star`-k murriztua (ez Class1.3).

Amaitzeko, guztiz konektatutako geruza guztien irteerak kateatu egiten dira iragarpen osoa lortzeko.

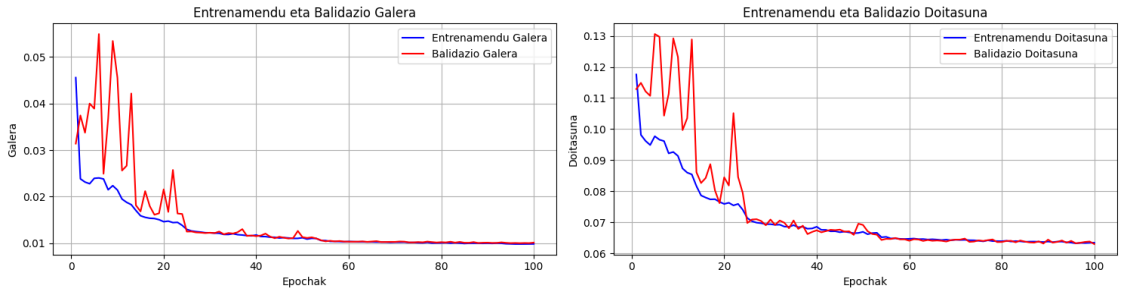
4 Emaitzen azterketa

Eredua hasierako $0{,}001$ ikaskuntza-tasarekin 100 epochen zehar entrenatu da. Horrez gain, 10 epocheko pazientzia zehaztu da gelditze goiztiarrerako. Erabilitako teknika batzuk izan dira: Mean Squared Error (MSE) galera funtziorako, *Adam* optimizatzailea eta $0{,}0005$eko pisuen gainbehera, *ReduceLROnPlateau* 5eko pazientziarekin ikaskuntza-tasa murrizteko. Diluzioa (dropout) ez da erabili eredua hobetzen ez duelako lagundu; bestetik, pisuen gainbehera gehitzeak gehien lagundu du.

Ereduaren entrenamenduaren eta balidazioaren begiztek 2h 35min iraun dute. 97. epochean $0{,}009\,99$ko balidazio galera hoberena lortu da. 100. epochean $0{,}063$ko balidazio doitasun hoberena lortu da.

2 Irudian garatutako ereduaren kostu eta doikuntza balioak, bai entrenamendu azpi-multzoan, bai balidazio azpi-multzoan, nola aldatu diren entrenamenduan zehar ikusi daitezke.

Gelditze goiztiarrak ez du entrenamendua gelditu. Ikusi dezakegu balidazio sortak tontor batzuk izan dituela, baina entrenamendu sortarekin konbergitzen hasten da 20. epochean. Bi sortetan galera murriztea eta doitasuna handitzea lortu dugu 50. epoch arte, non konbergitzen hasi dira. Une honetan $J \approx 0{,}01$eko galera eta $\%\ 6{,}5$eko doikuntza (MAE)



Irudia 2: Eredua entrenatu ondoren entrenamendu eta balidazio azpi-multzotatik lortutako kostu eta doikuntza metriken grafikoak.

lortu ditugu, eta ondorengo epochetan leuntzen jarraitu du. Ereduak ondo orokortu du balidazio sorta gainegokitzapenik gabe eta doitasun ona mantendu entrenamenduan eta balidazioan.

Azkenik, eredua aurretik ikusi gabeko datu berriekin probatu da; metrika garrantzitsuena. Proba datu-multzoan 0,009 959ko proba galera eta % 6,33ko proba doikuntza lortu dira. Beraz, ereduak ikasitakoa ondo orokortu du.

5 Ondorioak

ResNet arkitektura erabiliz erronkan proba doikuntza oso ona lortu dugu. Doikuntza are eta gehiago hobetzea nahi bada, hurrengo urrats hauek jarraitu litezke:

- Lagin gehiago erabili. Jada lagin guztiak erabiltzen ari badira, irudiei oraindik eta aldaketa gehiago egin data augmentation erabiliz.
- Eredua sakonagoa egin: bloke gehiago gehitu.
- Scheduler ezberdinak eta pisuen gainbeheraren hiperparametro balio ezberdinak probatu.
- Ereduaren epoch gehiagoren zehar entrenatu.

Hala ere, entrenamendu denborak nahiko luzeak dira, eta, beraz, urrats hauek lan honen irismenetik kanpo utzi dira.

6 Colab Notebook-en esteka

Landu den arazoari aurre egiteko garatutako ereduaren pausoz pausoko entrenamendu eta proba gida jarraian agertzen den Jupyter notebook-ean ikuskatu daiteke:

`https://drive.google.com/file/d/1KhnsTCOFv3uVulHG8xwOzXQm_p7LcIZl/view?usp=sharing`

Akronimoa

CNN Convolutional Neural Network. 1, 3–5

MSE Mean Squared Error. 5

ResNet Residual Neural Network. 1, 4, 6

Erreferentziak

[1] Kaiming He, Xiangyu Zhang, Shaoqing Ren, and Jian Sun. Deep residual learning for image recognition, 2015.